

Detección y clasificación de eventos acústicos de aves presentes en Colombia mediante aprendizaje profundo

Santiago Correa Marulanda

Ingeniería de Sistemas, Universidad de Antioquia
Medellín, Colombia

email: santiago.correa7@udea.edu.co

1. Contexto de aplicación

El monitoreo acústico pasivo (PAM) utiliza grabadoras autónomas para registrar los sonidos de un ecosistema durante periodos largos. En aves es una herramienta útil porque permite capturar actividad acústica de un hábitat natural con una metodología no invasiva. El problema es: Un muestreo con esta técnica puede producir muchas horas de audio y revisarlas manualmente no escala bien.

En este proyecto se busca automatizar parte de esa revisión, con especial interés en el monitoreo de aves presentes en Colombia. La idea es recibir una grabación, localizar las regiones del espectrograma que corresponden a eventos acústicos de aves y, para los eventos detectados, estimar qué especie produjo la vocalización. Este enfoque es útil en paisajes sonoros neotropicales, donde pueden aparecer varias especies al mismo tiempo y una etiqueta global para toda la grabación pierde información sobre cuándo y en qué banda de frecuencia ocurrió cada evento [1, 2].

2. Objetivo de Machine Learning

El sistema tendrá dos etapas. La primera es un **detector**: dada una representación tiempo–frecuencia del audio, debe predecir regiones delimitadas por $(t_{\min}, t_{\max}, f_{\min}, f_{\max})$ que contengan actividad acústica de aves. La segunda es un **clasificador**: dada una región detectada, debe asignarle una de las 30 especies objetivo o la clase `OTHER_SPECIES`.

Matemáticamente, para una grabación $x(t)$ queremos obtener eventos de la forma

$$(\hat{c}, \hat{t}_{\min}, \hat{t}_{\max}, \hat{f}_{\min}, \hat{f}_{\max}, \hat{s}), \quad (2.1)$$

donde $\hat{c}$ es la clase estimada y $\hat{s}$ una puntuación de confianza. Por tanto, no queremos únicamente predecir si “hay un ave” en el audio: queremos localizar cada evento y después clasificarlo.

3. Dataset

3.1. Fuentes y tipo de datos

El corpus se construyó a partir de cuatro fuentes: *PteroSet* [1], con grabaciones realizadas en Colombia; *WABAD-CO*, que corresponde al subconjunto colombiano de WABAD [4]; el dataset de paisajes sonoros del suroeste de la Amazonía grabado en Perú [5]; y el dataset de fincas cafeteras de Colombia y Costa Rica [6], que en este informe se denomina *Col-CR*.

La selección de las especies objetivo se centra en aves con evidencia de presencia en las fuentes colombianas, las grabaciones procedentes de Perú y Costa Rica permiten incorporar ejemplos adicionales de algunas de estas especies y ampliar la diversidad de condiciones acústicas representadas en el corpus.

Los datos principales son archivos de audio y anotaciones fuertes. Cada anotación fuerte delimita un evento mediante un intervalo temporal $[t_{\min}, t_{\max}]$ y un intervalo frecuencial $[f_{\min}, f_{\max}]$. Parte de los eventos también tiene identificación taxonómica a nivel de especie. Los audios usados por el proyecto fueron normalizados a 32 kHz y un canal, el corpus normalizado ocupa aproximadamente **[17.91 GB]** en disco.

3.2. Tamaño del corpus

Las cuatro fuentes suman 1 011 grabaciones, aproximadamente 135.17 horas de audio y 48 465 anotaciones. La Tabla 1 resume su composición.

No todos los eventos se usan de la misma forma. Para el detector se conservan los eventos con geometría tiempo–frecuencia válida, lo que deja 48 430 ejemplos. Se descartaron 35 anotaciones con límites inválidos o degenerados. Los eventos sin especie identificada siguen siendo útiles para el detector, porque continúan indicando dónde existe un evento acústico.

Para el clasificador se requiere una especie identificada y una anotación válida. El conjunto final contiene 25 589 eventos: 14 405 pertenecen a las 30 especies objetivo y 11 184 se agrupan en `OTHER_SPECIES`. Esta

Table 1. Tamaño del corpus antes de los filtros de modelado

Dataset	Audios	Etiq.	No etiq.	Eventos	Horas
PteroSet	563	6 702	8 670	15 372	73.62
Col-CR	34	6 952	386	7 338	34.00
Perú	21	14 798	1 684	16 482	21.00
WABAD-CO	393	9 273	0	9 273	6.55
Total	1 011	37 725	10 740	48 465	135.17

última clase representa especies identificadas que no forman parte del conjunto objetivo, no representa ruido ni eventos sin identificar.

3.3. Distribución de las clases

El proyecto se enfoca en 30 especies con evidencia de presencia en los datasets colombianos. Para seleccionarlas se exigió un mínimo de 200 eventos y presencia en al menos 15 grabaciones, considerando los ejemplos disponibles en el corpus integrado. Las especies identificadas que no pertenecen al conjunto objetivo, pero también tienen presencia en las fuentes colombianas, se agrupan en la clase **OTHER_SPECIES**.

La distribución de las clases es desbalanceada: **OTHER_SPECIES** es la clase más grande y, entre las especies objetivo, los conteos van desde 200 hasta 1 168 eventos. Esto será importante durante el entrenamiento y la evaluación, por lo que no se utilizará únicamente accuracy.

Table 2. Distribución de eventos del clasificador.

Clase	Eventos
OTHER_SPECIES	11 184
<i>Arremon brunneinucha</i>	717
<i>Atlapetes schistaceus</i>	252
<i>Attila spadiceus</i>	200
<i>Camptostoma obsoletum</i>	255
<i>Campylorhynchus turdinus</i>	951
<i>Cantorchilus leucotis</i>	824
<i>Colibri cyanotus</i>	498
<i>Crypturellus cinereus</i>	789
<i>Crypturellus soui</i>	248
<i>Crypturellus undulatus</i>	611
<i>Cyanocorax violaceus</i>	914
<i>Dendrocolaptes certhia</i>	204
<i>Empidonax virescens</i>	205
<i>Leptotila rufaxilla</i>	332
<i>Leptotila verreauxi</i>	506
<i>Momotus momota</i>	611
<i>Myiarchus tuberculifer</i>	252
<i>Nyctidromus albicollis</i>	279
<i>Pachyrhamphus polychopterus</i>	541
<i>Patagioenas plumbea</i>	271
<i>Pheugopedius rutilus</i>	358
<i>Pitangus sulphuratus</i>	482
<i>Psarocolius angustifrons</i>	716
<i>Ramphastos tucanus</i>	272
<i>Synallaxis azarae</i>	306
<i>Tolmomyias flaviventris</i>	431
<i>Turdus leucomelas</i>	233
<i>Tyrannus melancholicus</i>	374
<i>Xiphorhynchus guttatus</i>	605
<i>Zonotrichia capensis</i>	1 168

4. Métricas de desempeño

Como el sistema tiene dos tareas diferentes, las métricas también se separan.

Detector. La métrica principal para evaluar la detección será Average Precision (AP), considerando una predicción correcta cuando exista suficiente solapamiento entre la región predicha y la anotación. Se reportará AP utilizando IoU (*Intersection over Union*) con un umbral de 0.5. Como medida complementaria se utilizará IoMin (*Intersection over Minimum*), debido a que los límites exactos de una vocalización pueden ser ambiguos y una predicción contenida dentro de la anotación puede seguir siendo útil aunque presente un IoU reducido [2]. También se reportarán precisión, recall y F1 para un umbral de confianza determinado.

Clasificador. Se reportarán precisión, recall y F1 por clase, además de la matriz de confusión. Debido al desbalance en el número de eventos disponibles para cada especie, la métrica principal será Macro-F1:

$$F1_{macro} = \frac{1}{C} \sum_{c=1}^C F1_c, \quad C = 31. \quad (4.1)$$

Esta métrica asigna el mismo peso a cada clase, evitando que el resultado global quede dominado por **OTHER_SPECIES** o por las especies con mayor número de ejemplos.

Métrica operativa. Para estimar el impacto práctico del sistema se medirá el número de falsos positivos por hora de audio (FP/h). Una cantidad elevada de falsas detecciones incrementaría el trabajo de revisión manual, incluso si las métricas globales del modelo son buenas. Debido a que FP/h puede reducirse a costa de omitir eventos reales, esta métrica se analizará conjuntamente con el recall del detector.

5. Referencias y resultados previos

Hay tres antecedentes cercanos al problema del proyecto. Primero, PteroSet no solo aporta parte de los datos, sino que presenta una base de detección binaria de actividad aviar con ResNet-18. En validación cruzada reporta un F1 promedio de 0.718, AUPRC de 0.797, precisión de 0.712, recall de 0.749 y accuracy de 0.850 [1]. Esta tarea es más simple que la localización de cajas que se plantea aquí, pero sirve como referencia sobre la dificultad del dominio.

BirdNET es un antecedente importante para la parte de clasificación. Kahl et al. entrenaron una red profunda para reconocer 984 especies de Norteamérica y Europa y reportaron un mAP de 0.791 en grabaciones de una sola especie y un $F_{0.5}$ de 0.414 en paisajes sonoros anotados [3]. Los valores no son directamente comparables con nuestro proyecto porque cambian las especies, los datasets y la tarea, pero muestran que la clasificación automática de aves a gran escala es viable.

Finalmente, Hexeberg et al. formulan explícitamente la localización de vocalizaciones como detección de objetos sobre espectrogramas. Su mejor modelo YOLO11 obtuvo 81.8% de F1 con IoMin@50 en datos de Singapur y 58.6% en grabaciones fuera de distribución de Hawái [2]. Este trabajo es relevante para nuestra primera etapa, ya que plantea el mismo tipo de salida tiempo–frecuencia que queremos producir.

Estos resultados se tomarán como referencias, no como objetivos de comparación. La evaluación final deberá hacerse sobre los modelos aquí construidos y sobre las 30 especies objetivo más `OTHER_SPECIES`.

References

- [1] D. Ruiz, J. S. Ulloa, Z. Miao, et al., “A strongly annotated passive acoustic dataset for tropical bird monitoring,” 2026. <https://arxiv.org/abs/2605.20578>
- [2] S. Hexeberg, F. Tong, H. Vishnu, and M. Chitre, “Time-frequency localization of bird calls in dense soundscapes,” 2026. <https://arxiv.org/abs/2606.10407>
- [3] S. Kahl, C. M. Wood, M. Eibl, and H. Klinck, “BirdNET: A deep learning solution for avian diversity monitoring,” *Ecological Informatics*, vol. 61, p. 101236, 2021. <https://doi.org/10.1016/j.ecoinf.2021.101236>
- [4] C. Pérez-Granados et al., “WABAD: A World Annotated Bird Acoustic Dataset for Passive Acoustic Monitoring,” Zenodo, 2026. <https://doi.org/10.5281/zenodo.20513304>
- [5] W. A. Hopping, S. Kahl, and H. Klinck, “A collection of fully-annotated soundscape recordings from the Southwestern Amazon Basin,” Zenodo, 2022. <https://doi.org/10.5281/zenodo.7079124>
- [6] A. Vega-Hidalgo, S. Kahl, L. B. Symes, V. Ruiz-Gutiérrez, I. Molina-Mora, F. Cediell, L. Sandoval, and H. Klinck, “A collection of fully-annotated soundscape recordings from neotropical coffee farms in Colombia and Costa Rica,” Zenodo, 2023. <https://doi.org/10.5281/zenodo.7525349>